

PREVISÃO DE PÚBLICO EM SHOWS DE K-POP COM APRENDIZADO DE MÁQUINA: UM ESTUDO DE FEATURE ABLATION COM DECISION TREE, RANDOM FOREST E MLP

Sofia Alves Toreti

Resumo: Este trabalho desenvolve e avalia um pipeline de regressão supervisionada para prever a frequência de público em shows de K-pop. O dataset bruto contém 1.169 entradas com 29 atributos cobrindo artista, tour, local e mercado. A partir dele, foram geradas seis versões processadas do dataset, cada uma incorporando um grupo adicional de *features*, o que permitiu medir a contribuição isolada de cada conjunto via ablação. Três modelos foram comparados, Árvore de Decisão, Random Forest e Redes Neurais Artificiais (MLP), em 18 combinações no total. O melhor resultado foi R^2 de 0,9537, MAE de 4.120 e RMSE de 6.196, obtido com Random Forest sobre o dataset v2_artist. A ablação mostrou que *features* de artista são o principal fator preditivo: removê-las derruba o R^2 de 0,9534 para valores próximos a 0,35, confirmando que a identidade do artista domina a variância de público no contexto estudado.

Palavras-chave: aprendizado de máquina; regressão; K-pop; previsão de público; feature ablation.

Abstract: This work develops and evaluates a supervised regression pipeline to predict concert attendance for K-pop shows. The raw dataset contains 1,169 entries with 29 attributes covering artist, tour, venue, and market. Six processed versions of the dataset were generated, each incorporating an additional feature group, enabling isolated measurement of each group's contribution through ablation. Three models were compared, Decision Tree, Random Forest and Artificial Neural Network (MLP), in 18 combinations total. The best result was R^2 of 0.9537, MAE of 4,120 and RMSE of 6,196, achieved with Random Forest on the v2_artist dataset. Ablation showed that artist features are the dominant predictive factor: removing them drops R^2 from 0.9534 to values near 0.35, confirming that artist identity accounts for most of the variance in concert attendance within this context.

Keywords: machine learning; regression; K-pop; attendance prediction; feature ablation.

1. INTRODUÇÃO

A indústria de shows ao vivo de K-pop cresceu de forma expressiva ao longo dos anos 2010 e se tornou um mercado global relevante na década seguinte. Estimar o público antes da venda de ingressos tem valor prático direto para promotoras, arenas e agências: influencia a escolha do local de evento, a precificação e a quantidade de datas divulgadas.

O desafio é interessante do ponto de vista técnico uma vez que a variável alvo depende de fatores heterogêneos: a popularidade do artista, o tamanho e o tipo do local, o mercado geográfico, a época do ano e o formato da turnê. Não está claro, a princípio, qual desses grupos de variáveis mais explica a variância de público. Isso torna o problema adequado a um experimento de ablação, onde cada grupo é adicionado ou removido sistematicamente para medir sua contribuição.

O objetivo geral é construir e avaliar um pipeline de regressão para prever a variável *attendance* (quantidade de ingressos vendidos) a partir de atributos disponíveis antes da realização do show. Os objetivos específicos são: organizar o dataset em seis versões com grupos de *features* progressivamente mais ricos; comparar três algoritmos de regressão em cada versão; e responder, com evidência empírica, quais grupos de *features* mais afetam a precisão dos modelos.

2. DADOS E METODOLOGIA

2.1 Dataset

O dataset bruto contém 1.169 entradas referentes a shows de K-pop realizados entre 2016 e 2026. Cada entrada representa as apresentações de um artista em um local de evento específico durante uma turnê e reúne 29 atributos organizados em quatro grupos:

- **Artista:** *artist, gender, generation, members, debut, company*.
- **Tour e palco:** *tour, tour_type, stage_setup, show_nights*.
- **Local:** *continent, country, city, venue, venue_type, venue_capacity*.
- **Métricas de desempenho:** *attendance, fill_rate, box_score, avg_ticket_price, reporting_status*.

A variável alvo é *attendance*: total de ingressos vendidos para todas as noites do artista naquele local de evento. Três colunas (*fill_rate, box_score, avg_ticket_price*) são derivadas direta ou indiretamente de *attendance* e foram removidas de todos os datasets processados para evitar vazamento de dados.

O campo *generation* classifica artistas em quatro grupos segundo o período de estreia: 2ª geração (2000–2012), 3ª (2012–2017), 4ª (2017–2023) e 5ª (2023–presente). Artistas de 2ª e 3ª geração sustentam relevância por legado; artistas de 4ª e 5ª estão atrelados ao consumo corrente. A variável *stage_setup* distingue palcos *end stage* (plateia em 180°) de *center stage* (360°), o que pode dobrar a capacidade efetiva do mesmo local de evento (um estádio, por exemplo).

2.2 Fontes de dados

Os dados foram coletados de quatro agentes de reporte: Touring Data, Pollstar, KOPIS e, ocasionalmente, Billboard Boxscore.

A Touring Data é um agente independente que recebe os resultados de shows voluntariamente das promotoras de eventos. Por ser um reporte voluntário, a cobertura geográfica é desigual: a maioria dos registros de K-pop vem da América do Norte e Europa, com presença menor da Oceania e América do Sul. Shows asiáticos são os menos frequentes na base e, quando aparecem, tendem a estar associados à própria empresa gestora do artista assumindo o papel de promotora e reportando os dados diretamente.

A Pollstar é uma publicação especializada em dados da indústria de shows ao vivo, com foco no mercado norte-americano e europeu. Coleta e agrega resultados de bilheteria a partir de promotoras, locais de evento e relatórios públicos da indústria, e é uma das referências mais estabelecidas do setor para ranqueamentos de tours e artistas por receita.

A KOPIS (Korea Performing Arts Box Office Information System) é um sistema governamental sul-coreano mantido pela Arts Management Support Center, vinculado ao Ministério da Cultura, Esporte e Turismo Sul Coreano. Agrega dados de reserva e cancelamento de ingressos de mais de 200 agências de ticketing credenciadas desde a revisão da Lei de Performances em 2019, o envio de dados à KOPIS passou a ser obrigatório para todos os shows realizados na Coreia do Sul

O Billboard Boxscore é o sistema de reporte de receita de shows da Billboard, baseado em declarações voluntárias de promotoras. Cobre principalmente eventos de grande porte no mercado norte-americano e é referência para ranqueamentos de tours por receita bruta, que serve também para premiações americanas.

A coluna *reporting_agent* identifica a fonte de cada entrada. A coexistência de múltiplos agentes introduz variação metodológica: cada fonte agrega e arredonda os números de forma ligeiramente diferente, o que pode gerar pequenas inconsistências em casos onde o mesmo show é coberto por mais de um agente.

2.3 Pré-processamento

O pipeline aplica os seguintes passos:

- A. Remoção de linhas sem *attendance* ou sem *venue_capacity*;
- B. Filtro por *reporting_status* == 'reported' quando a coluna está presente;
- C. Remoção das colunas com vazamento (*fill_rate*, *box_score*, *avg_ticket_price*);
- D. Criação de *years_since_debut* (diferença entre *day_1* e *debut* em anos);
- E. Criação de *is_weekend* (1 para Sex/Sáb/Dom, 0 para demais dias);
- F. Extração de *show_year* e *show_month* a partir de *day_1*;
- G. *One-hot* encoding das variáveis categóricas;
- H. Escalonamento com *StandardScaler*.

2.4 Versões do dataset

A ablação é estruturada em seis versões do dataset. Cada versão adiciona um grupo de *features* sobre a anterior, com exceção de v6, que parte do modelo completo e remove a identidade do artista.

Versão	Features	Hipótese
v1_baseline	Local + Geografia	Localização e capacidade explicam parte do público
v2_artist	v1 + Artista	Popularidade do artista supera o efeito do venue
v3_artist_geo	v2 + Interação artista × país	Artistas têm desempenhos distintos por mercado
v4_artist_geo_time	v3 + Tempo	Sazonalidade e ciclo econômico têm efeito
v5_full	Todas as features	Modelo com maior cobertura de informação
v6_no_artist	v5 sem artist e company	Teste de dependência da identidade do artista

2.5 Modelos

Foram utilizados três modelos do *scikit-learn*:

- **Árvore de Decisão**: modelo interpretável baseado em partições binárias do espaço de *features*. Propenso a *overfitting* em árvores profundas.
- **Random Forest**: *ensemble* de árvores com *bagging* e seleção aleatória de features. Reduz variância sem aumento proporcional de viés.

- **MLP**: rede neural densa com camadas ocultas. Capaz de capturar relações não lineares complexas, mas sensível à escala das features e ao ajuste de hiperparâmetros.

2.6 Avaliação

Os modelos foram avaliados com divisão treino/teste de 80/20 e semente aleatória 42. As métricas utilizadas foram:

- **R²** (coeficiente de determinação): fração da variância de *attendance* explicada pelo modelo;
- **MAE** (Mean Absolute Error): erro médio absoluto em número de pessoas;
- **RMSE** (Root Mean Squared Error): erro médio com penalização de outliers.

R² é a métrica principal para comparar versões e modelos. MAE e RMSE contextualizam os erros em unidades interpretáveis.

3 EXPERIMENTOS E RESULTADOS

3.1 Resultados por dataset e modelo

A Tabela 1 apresenta os resultados dos 18 experimentos.

Tabela 1 – R², MAE e RMSE por versão de dataset e modelo

Dataset	Modelo	MAE	RMSE	R ²
v1_baseline	Decision Tree	5.090	8.582	0,9112
v1_baseline	MLP	11.566	17.870	0,615
v1_baseline	Random Forest	4.655	7.311	0,9356
v2_artist	Decision Tree	5.327	9.063	0,901
v2_artist	MLP	11.528	17.068	0,6488
v2_artist	Random Forest	4.120	6.196	0,9537
v3_artist_geo	Decision Tree	5.537	9.615	0,8886
v3_artist_geo	MLP	11.687	19.521	0,5406
v3_artist_geo	Random Forest	4.145	6.308	0,952
v4_artist_geo_time	Decision Tree	5.613	11.669	0,8359
v4_artist_geo_time	MLP	11.678	18.839	0,5722
v4_artist_geo_time	Random Forest	4.187	6.307	0,952

v5_full	Decision Tree	5.754	9.664	0,8874
v5_full	MLP	11.381	16.626	0,6668
v5_full	Random Forest	4.167	6.216	0,9534
v6_no_artist	Decision Tree	4.794	7.961	0,9236
v6_no_artist	MLP	10.290	15.334	0,7165
v6_no_artist	Random Forest	4.279	6.420	0,9503

3.4 Comparação entre modelos

O Random Forest foi o modelo mais consistente em todas as versões. A Árvore de Decisão mostrou desempenho inferior em datasets com muitas features categóricas codificadas, resultado esperado por sua tendência ao overfitting. O MLP apresentou resultados competitivos, mas abaixo do Random Forest, possivelmente por limitação de hiperparâmetros com a configuração padrão do scikit-learn.

O melhor resultado absoluto é Random Forest no dataset v2_artist ($R^2 = 0,9537$, MAE = 4.120, RMSE = 6.196). O fato de v2 superar v5 indica que features adicionais introduzidas nas versões posteriores não acrescentam informação suficiente para compensar o ruído que introduzem.

4. DISCUSSÃO

4.1 O papel da identidade do artista

O resultado mais claro do experimento é que a identidade do artista domina a variância de público. Com *artist* presente, o Random Forest explica 95% da variância. Sem ela, cai para 35%. Isso não é surpreendente: no K-pop, a popularidade de um artista é altamente concentrada — alguns grupos vendem 50.000 ingressos por noite com frequência enquanto outros raramente passam de 5.000. Localização e tipo de venue explicam menos porque são, em parte, consequência dessa popularidade (artistas maiores tocam em venues maiores).

Essa dependência tem uma implicação prática importante: o modelo generaliza mal para artistas novos ou sem histórico no dataset. A variável *artist* é tratada como categórica com one-hot encoding, o que significa que um artista ausente no treino recebe vetor zero e o modelo não consegue distingui-lo de qualquer outro artista fora da amostra.

4.2 Por que v2 supera v5

O dataset `v2_artist` contém apenas as features de venue, geografia e artista. Os grupos adicionados em `v3`, `v4` e `v5` introduzem interação artista $\times$ país e variáveis temporais. O ganho marginal dessas features é pequeno (menos de 0,002 de R^2) e pode ser compensado pelo custo de dimensionalidade e eventual ruído introduzido pela interação. Random Forest com configuração padrão pode não ter profundidade ou número de árvores suficientes para aproveitar essas relações adicionais de forma eficiente.

4.3 Features temporais

A hipótese de que sazonalidade e ciclo econômico afetam o público não foi confirmada pelos resultados. O delta de R^2 na transição `v3` $\rightarrow$ `v4` é marginal ou levemente negativo para o Random Forest. Isso não significa que o efeito temporal não existe, mas que, dentro deste dataset e com estes modelos, a variância explicada por tempo é pequena em relação à variância já capturada pela identidade do artista.

4.4 Limitações

O dataset é restrito ao K-pop e não generaliza para outros gêneros musicais. A divisão treino/teste é simples, sem validação cruzada ou validação temporal. Artistas com poucas entradas no dataset terão estimativas menos confiáveis. A ausência de dados sobre preço médio de ingresso (removido por vazamento) elimina um preditor potencialmente relevante que só estaria disponível em produção se calculado a partir de fontes externas.

5. CONSIDERAÇÕES FINAIS

Este trabalho construiu um pipeline de regressão para previsão de público em shows de K-pop e avaliou sistematicamente a contribuição de seis grupos de features via ablação. O Random Forest sobre o dataset `v2_artist` produziu o melhor resultado: R^2 de 0,9537, MAE de 4.120 pessoas e RMSE de 6.196 pessoas.

A conclusão principal é que a identidade do artista é o fator dominante. Features de localização, interação geográfica e tempo têm impacto secundário quando o artista está presente no modelo. Remover a identidade do artista faz o R^2 cair de 0,95 para aproximadamente 0,35, mostrando que o modelo atual depende fortemente de ter visto cada artista durante o treinamento.

Como trabalhos futuros, destacam-se: incorporar validação temporal (treinar em anos anteriores e testar em anos mais recentes); explorar embeddings de artista baseados em métricas externas de popularidade (streams, seguidores) em vez de one-hot encoding;

avaliar modelos de gradient boosting (XGBoost, LightGBM); e construir uma estratégia explícita para artistas não vistos no treino.