




Previsão de Público em Shows de K-pop com Aprendizado de Máquina

SOFIA ALVES TORETI

O Problema

Por que prever?


Escolha de local, precificação e divulgação de datas dependem da estimativa de público

O desafio

Popularidade, venue, mercado e sazonalidade criam variância heterogênea

A abordagem

Ablação sistemática: medir a contribuição isolada de cada grupo de features



Dataset



1.169 entradas

Shows de K-pop entre 2016 e 2026

29 atributos

Artista, tour, local e métricas de desempenho

Variável alvo

attendance — ingressos vendidos por noite

Fontes


Touring Data, Pollstar, KOPIS e Billboard Boxscore

Pipeline de Pré-processamento



Remoção de *fill_rate*, *box_score* e *avg_ticket_price* evita vazamento de dados —derivadas direta ou indiretamente de *attendance*.

As 6 Versões do Dataset



Cada versão adiciona um grupo de features sobre a anterior — exceto **v6**, que remove a identidade do artista para testar dependência.

i A ablação mede a contribuição marginal de cada grupo sobre o R^2

Os Três Modelos



Decision Tree

Partições binárias interpretáveis. Propenso a *overfitting* em árvores profundas.




Random Forest

Ensemble com *bagging*. Reduz variância sem aumento de viés.




MLP

Rede densa com camadas ocultas. Captura relações não lineares complexas.



Resultados: R² por Dataset e Modelo



Random Forest domina em todas as versões. O melhor resultado absoluto: **v2_artist** com **R² = 0,9537**.

Melhor Resultado: Random Forest em v2_artist

0,9537

R^2

Variância explicada

4.120

MAE

Pessoas (erro médio)

6.196

RMSE

Pessoas (outliers penalizados)

18


Combinações

3 modelos $\times$ 6 datasets

✓ v2 supera v5: features adicionais introduzem ruído sem ganho preditivo suficiente

O Papel Dominante da Identidade do Artista


Condição



A queda é dramática

Remover **artist** e **company** derruba o R^2 de **0,95** → **~0,35**

- Artistas maiores tocam em venues maiores — local é consequência da popularidade
- Artistas novos sem histórico no treino recebem vetor zero no one-hot encoding
- Features temporais e geográficas têm impacto secundário quando o artista está presente



Considerações Finais e Trabalhos Futuros

1

Validação temporal

Treinar em anos anteriores, testar em anos mais recentes

2

Embeddings de artista

Streams e seguidores no lugar do one-hot encoding

3

Gradient Boosting

XGBoost e LightGBM como alternativas ao Random Forest

4

Artistas não vistos

Estratégia explícita para generalização a novos artistas

Obrigada!

Perguntas?